

SESSÃO 1 · USUÁRIO TÉCNICO

Engenharia de Dados na Databricks

Construção do pipeline medalhão (Bronze → Silver → Gold) no Unity Catalog — ingestão com Auto Loader, qualidade de dados e modelagem, até os dados aterrissarem no catálogo que a Sessão 2 consome.

 17 de setembro de 2026

 **09h00–11h00** (BRA)

 2 horas

 Engenheiros & times de dados (técnico)

O dia em duas sessões: **09h00–11h00 — Usuário Técnico (esta sessão): Data Engineering**
· 11h00–13h00 — Usuário de Negócio: AI/BI + Genie.



Workshop de dia inteiro · 2 sessões

Uma narrativa contínua: a Sessão 1 (técnica) constrói o pipeline que aterrissa os dados no catálogo; a Sessão 2 (negócio) os transforma em autoatendimento com AI/BI + Genie.

 **Sessão 1 · 09h–11h** — Data Engineering (técnico)

 **Sessão 2 · 11h–13h** — Usuário de Negócio (AI/BI + Genie)

origens → **Bronze** → **Silver** → **Gold** → Metric Views (semântica) → Genie + Dashboards (negócio)

Sessão 1 · Data Engineering — 09h00–11h00 (técnico)

Construção do pipeline medalhão (Bronze → Silver → Gold) no Unity Catalog, com ingestão via Auto Loader, qualidade de dados e modelagem — até os dados aterrissarem no catálogo que a Sessão 2 consome.

09h00 – 09h10

10 min

1 · Arquitetura Lakehouse & medalhão

Unity Catalog, Lakeflow, schema + Volume.

09h10 – 09h35

25 min

2 · Ingestão (Bronze)

Auto Loader / read_files / COPY INTO → Bronze cru.

09h35 – 10h05

30 min

3 · Transformação (Silver → Gold)

Tipagem, dedup, qualidade + dimensões e fatos.

10h05 – 10h30

25 min

4 · Preparação de Dados & Machine Learning

Features + treinar modelo de fraude, orquestrado após o pipeline.

10h30 – 10h50

20 min

5 · Databricks Apps & AI Gateway

Criar um app e governar o consumo de IA.

10h50 – 11h00

10 min

6 · Orquestração & Governança

Job (pipeline→treino→dashboard), lineage, tags · handoff.

Bloco 1 09h00–09h15 Arquitetura Lakehouse & medalhão

Bronze → Silver → Gold é o refino progressivo: cru fiel à origem → limpo, tipado e deduplicado → modelo de negócio. Tudo governado pelo **Unity Catalog** e orquestrado pelo **Lakeflow** (Declarative Pipelines + Jobs). Criamos o schema `metlife_medallion` e um **Volume** de landing.

Bloco 2 09h15–09h45 Ingestão — camada Bronze

Ingestão incremental com **Auto Loader** (`STREAM read_files`), **COPY INTO** (batch idempotente) ou conectores. O Bronze preserva o dado **cru** (tudo texto, categorias fora de padrão), com colunas técnicas de ingestão (`_arquivo`, `_ingestao`).

LAB TÉCNICO

- Materializar as 7 origens em `bronze_*` fiéis ao cru.
- Conferir tipos (tudo `string`) e volumetria por origem.

Bloco 3 09h35–10h05 Transformação — Silver → Gold

Silver: tipagem, padronização de categorias, **deduplicação** e **qualidade** declarativa (`CONSTRAINT ... EXPECT (...) ON VIOLATION DROP ROW`) com tabela de **quarentena**. **Gold**: dimensões conformadas e fatos prontos, preservando o que o negócio

filtra (linha, canal, região, produto, tempo) + colunas derivadas (faixa de capital, mês de competência). É o formato que a **Sessão 2** consome.

LAB TÉCNICO

- Silver tipado + dedup + regras de qualidade em apólices (prêmio ≥ 0 , linha válida) + quarentena.
- Promover a Gold (dimensões + fatos) com colunas de negócio derivadas.

✓ **Checkpoint:** o Gold reconcilia com a origem — 8.000 apólices · 177.523 prêmios · 2.500 sinistros.

Bloco 4 10h05–10h30 **Preparação de Dados & Machine Learning**

Com o Gold pronto, preparamos *features* e treinamos um modelo de **propensão a fraude em sinistros** — classificação que gera um **score de risco** para priorizar investigação (rótulo `suspeita_fraude` disponível no Gold).

LAB TÉCNICO · ML

- **Modelo:** Gradient-Boosted Trees (Spark MLlib); baseline Regressão Logística; **AutoML** como acelerador.
- **MLOps:** MLflow + **Unity Catalog Model Registry** (`metlife_pipeline.modelo_fraude`).
- **Orquestração:** o treino é uma **task do Job dependente do pipeline** — re-treina quando o Gold muda.

✓ **Checkpoint:** modelo registrado e versionado no UC, pronto para servir sob AI Gateway.

Bloco 5 10h30–10h50 **Databricks Apps & AI Gateway**

Databricks Apps publica aplicações web (FastAPI/Streamlit) **dentro do Databricks**, com identidade e governança do Unity Catalog. Construímos um app de **triagem de sinistros** que lê o Gold e ranqueia os casos de maior risco de fraude.

LAB TÉCNICO · APPS

- Scaffold app.yaml + FastAPI (apps/metlife_triagem/) → databricks apps deploy.
- **AI Gateway** governa o consumo de IA (Model Serving): rate limits, usage tracking, payload logging (inference tables), guardrails e fallbacks.

Bloco 6 10h50–11h00 Orquestração & Governança · handoff

Um único **Lakeflow Job** encadeia o dia: **Task 1** roda o pipeline (Bronze→Silver→Gold); ao concluir, **Task 2** re-treina o modelo de fraude e **Task 3** atualiza o **dashboard AI/BI** — dados, modelo e painel sempre **sincronizados**. Com **lineage** automático (bronze → silver → gold → modelo/Metric Views → Genie/dashboards), **tags de Domain** e **AI Gateway** no consumo de IA. O ambiente já tem pipeline e Job provisionados.



Pipeline (Lakeflow) ao vivo



Job de orquestração



Notebook da Sessão 1

▼ A seguir, a **Sessão 2 · Usuário de Negócio** — consumo do Gold com AI/BI + Genie.

O que você vai conseguir fazer

Ao final desta sessão, você domina o autoatendimento analítico na plataforma.



Navegar a plataforma

Entender onde AI/BI e Genie se encaixam, com a governança do Unity Catalog.



Construir um dashboard AI/BI

KPIs, gráficos e filtros — sem escrever uma linha de código.



Conversar com o Genie

Perguntar em português e interpretar a resposta, o gráfico e o insight.



Confiar na resposta

Instruções, sinônimos, Metric Views, Domain e glossário — a base do Genie

Agenda · 2 horas

Seis blocos sequenciais, do contexto ao encerramento.

11h00 – 11h10

10 min

1 · Abertura e a visão de AI/BI para seguros

Por que análise conversacional; tour rápido da plataforma.

11h10 – 11h40

30 min

2 · Dashboards AI/BI (mão na massa)

Construir seu primeiro dashboard, sem código.

11h40 – 12h20

40 min

3 · Genie — conversa em linguagem natural

Perguntar, ler a resposta e confiar.

12h20 – 12h45

25 min

4 · Genie confiável — curadoria e camada semântica

Instruções, sinônimos, Metric Views, Domain, glossário e Ontology.

12h45 – 12h55

10 min

5 · Casos de uso MetLife

Fraude, distribuição e persistência.

12h55 – 13h00

5 min

6 · Encerramento e jornada de adoção

Próximos passos e Q&A.

Passo a passo da aula

Cada bloco tem objetivo, o que fazer e um checkpoint. Você trabalha nas telas do Dashboard e do Genie.

Bloco 1 11h00–11h10 Abertura e a visão de AI/BI para seguros

Áreas de negócio vivem esperando relatórios. **AI/BI + Genie** invertem isso: qualquer pessoa pergunta em linguagem natural sobre dados **governados** e recebe tabelas e gráficos — com a segurança do Unity Catalog. Usamos uma seguradora fictícia (formato MetLife) com três domínios: Carteira/Distribuição, Arrecadação e Sinistros/Fraude.

✓ **Checkpoint:** você localiza o catálogo do workshop e entende a diferença entre apólices de Vida (capital segurado) e Previdência (reserva).

Bloco 2 11h10–11h40 Dashboards AI/BI — mão na massa

Um dashboard AI/BI é montado sobre dados do Unity Catalog com KPIs, gráficos e filtros — sem código. Primeiro vemos um pronto, depois você constrói o seu.

LAB A • SEU PRIMEIRO DASHBOARD

1. Menu lateral → **Dashboards** → **Create dashboard**.
2. Aba **Data** → adicione a tabela apólices.
3. Aba **Canvas**: KPI de apólices ativas · barras de prêmio por região · pizza por linha de negócio.
4. Adicione um **filtro** de linha de negócio e veja tudo reagir.
5. **Publish** e explore **Share**.

✓ **Checkpoint:** dashboard com 1 KPI + 1 gráfico + filtro. Sudeste lidera o prêmio.

Bloco 3 11h40–12h20 Genie — conversa em linguagem natural

O Genie traduz perguntas em linguagem natural para consultas governadas. Você lê a resposta, o gráfico e, se quiser, o SQL por trás.

LAB B • PERGUNTAR E CONFIAR

- "Quantas apólices ativas temos por linha de negócio?"
- "Qual o prêmio mensal total por região?"
- "Quais os 10 corretores com maior produção de prêmio?"
- Acompanhamento: "E somente na região Sudeste?" · "Mostre em um gráfico de barras."

✓ **Checkpoint:** perguntas claras + termos do negócio → o Genie acerta; ambíguas → ele pede esclarecimento (esperado).

Bloco 4 12h20–12h45 **Genie confiável — curadoria e camada semântica**

Por que o Genie responde bem aqui? Por causa da **curadoria** e da **camada semântica governada** — o coração do Genie Ontology.

LAB C • CURADORIA

- Veja **Instructions**, descrições e sinônimos no Genie Space.
- Pergunte com jargão: "Qual a mensalidade média das apólices de Vida ativas?" (entende "mensalidade" = prêmio).

LAB E • CAMADA SEMÂNTICA (METRIC VIEWS)

- No 2º Genie Space (só Metric Views): "Qual a taxa de arrecadação (persistência) por região?"
- "Qual o tempo médio de liquidação e a taxa de fraude por tipo de sinistro?"
- O Genie reutiliza a **métrica certificada** em vez de recalcular — consistência entre pessoas e dashboards.

✓ **Checkpoint:** você identifica os Metric Views, o glossário e as tags de Domain no Catalog Explorer.

Bloco 5 12h45–12h55 **Casos de uso MetLife**

Escolha um trilha e pergunte no Genie:

LAB D · TRILHOS

- **Sinistros & fraude:** "Quantos sinistros com suspeita de fraude e qual o valor reclamado?"
- **Distribuição:** "Qual canal tem o maior ticket médio de prêmio?"
- **Persistência:** "Qual a taxa de inadimplência por região?"

✓ **Checkpoint:** ≈261 sinistros suspeitos (10,4%), liquidação média ≈ 67 dias.

Bloco 6 12h55–13h00 **Encerramento e jornada de adoção**

Do workshop à produção: conectar os dados reais no Unity Catalog, criar Metric Views por domínio e um Genie Space por área, habilitar o preview do **Genie Ontology** e eleger 1 domínio piloto com 3–5 perguntas de alto valor.

Ambiente & acessos

Utilize essa demo no seu ambiente, consulte [Databricks Free Edition](#) e comece a utilizar.



Dashboard AI/BI de referência



Genie · tabelas



Genie · camada semântica



Repositório do workshop

Genie Ontology — a camada de confiança

O "mapa de negócio" que o Genie usa para responder com precisão e rastreabilidade.

Dois tipos de contexto

O que já deixamos pronto

1. Semânticas governadas que você *define* no Unity Catalog — Metric Views, Domains e Pages/glossário. É a fonte da verdade.

2. Contexto inferido — snippets extraídos automaticamente de dashboards, consultas e Genie Agents, com *authority scoring* por fonte, frequência e atualidade.

 **Preview:** o Genie Ontology (Genie One, nível de conta) está em Public Preview — a habilitação é feita pelo time de conta Databricks. Os blocos governados abaixo já estão prontos para serem consumidos.

3 Metric Views

Domain (tags UC)

Glossário · 13 termos

2 Genie Spaces

Dashboard AI/BI

Métricas canônicas (prêmio, sinistralidade, inadimplência, persistência, taxa de fraude) definidas uma única vez e reutilizadas por Genie e dashboards.

Números de bolso (gabarito)

Valores aproximados da base sintética — para conferir as respostas do Genie.

2.801

apólices de Vida
ativas

2.753

apólices de
Previdência ativas

~5,1%

taxa de
inadimplência

~95%

persistência
(arrecadação)

261

sinistros suspeitos
(10,4%)

196

sinistros de alto
risco

~67

dias de liquidação
média

177 mil

pagamentos de
prêmio



Material de capacitação preparado pela Databricks. Utiliza uma base **sintética** no formato MetLife (seguros de vida, previdência, sinistros e distribuição), criada exclusivamente para fins de treinamento — não contém dados reais nem PII. Logo MetLife usado apenas para identidade visual do workshop.