

TRACK TÉCNICO · SANDBOX DO CLIENTE

# Engenharia de Dados na Databricks

Self-service sobre a camada **Gold**: governança com Unity Catalog, CI/CD com Azure DevOps, Delta Sharing, ML e Apps — no workspace **sandbox** da MetLife.

 MetLife · 2026

 ~4h30 (meia-diária)

 Sandbox compartilhado

 Engenheiros & times de dados

**Escopo:** a ingestão (Bronze/Silver) é *upstream*, a cargo da Argentina; aqui o Brasil trabalha na **self-service zone** sobre o **Gold governado**. Cada participante usa seu próprio schema `scratch_<user>` no sandbox compartilhado.



## Agenda · meia-diária (~4h30)

Nove blocos, do isolamento no sandbox ao ciclo governado de ponta a ponta. Horário indicativo (início 09h00).

**09h00 – 09h10**

10 min

### 0 · Setup & isolamento

Schema scratch\_<user> por participante + acesso ao Gold.

**09h10 – 09h25**

15 min

### 1 · Arquitetura & posicionamento

Self-service zone sobre o Gold; medalhão em conceito.

**09h25 – 09h50**

25 min

### 2 · Trabalhando na camada Gold

Modelagem consumível + objetos derivados no seu schema.

**09h50 – 10h45**

55 min

### 3 · Governança Unity Catalog

Grants, tags/Domain, lineage, masking + row filter, audit e custo.

**10h45 – 11h00**

15 min



### Intervalo

—

**11h00 – 11h55**

55 min

### 4 · CI/CD com Azure DevOps + DABs

Repos + GitFlow, Asset Bundles, pipeline de deploy no sandbox.

**11h55 – 12h30**

35 min

### 5 · Delta Sharing (Open Sharing)

Provider compartilha o Gold; recipient consome (AR→BR).



**12h30 – 13h05**

35 min

### 6 · Preparação de dados & ML

Propensão a fraude: MLflow + UC Model Registry.



**13h05 – 13h35**

30 min

### 7 · Databricks Apps & AI Gateway

App de triagem sobre Gold + endpoint governado.



**13h35 – 13h50**

15 min

### 8 · Orquestração & handoff

Job encadeando Gold → treino → dashboard, com lineage.

## Passo a passo da aula

Cada bloco tem objetivo, laboratório e checkpoint. Você constrói no seu schema `scratch_<user>`; o Gold é somente leitura.

**Bloco 0**

### 09h00–09h10 Setup & isolamento no sandbox

O sandbox é **compartilhado** por todos os técnicos. Para ninguém pisar no trabalho do outro, cada participante cria seu **schema isolado** `scratch_<user>` e confirma o acesso ao **Gold** e ao **SQL warehouse serverless**. Regra de ouro: **Gold é somente leitura**; toda construção acontece no seu schema.



#### LAB · ISOLAMENTO

- Rodar `sandbox/sql/10_user_scratch.sql` (usa `current_user()` para nomear seu schema).
- Conferir SELECT nas tabelas do Gold.



**Checkpoint:** seu schema `scratch_<user>` criado e um SELECT no Gold funcionando.

## Bloco 1 09h10–09h25

### Arquitetura & posicionamento na Self-Service Zone

Onde estamos no **CAF Brasil DataHub**: a ingestão (Data Factory / Auto Loader → Bronze/Silver) é **upstream**, sob responsabilidade da **Argentina**. O **Brasil** opera a **self-service zone** — Databricks + Unity Catalog sobre o **Gold governado**, alimentando dashboards e Genie. O medalhão fica em **1 slide de conceito**: nosso ponto de partida é o Gold.

#### LAB · ONDE ESTÁ O GOLD

- Localizar o Gold no **Catalog Explorer** e entender a fronteira Gold ↔ upstream.

## Bloco 2 09h25–09h50 Trabalhando na camada Gold

Consumir o Gold: dimensões e fatos prontos, colunas de negócio derivadas (faixa de capital, mês de competência) e qualidade. Você cria objetos derivados **no seu schema**, sem tocar no Gold.

#### LAB · OBJETO DERIVADO

- Criar uma **view/tabela** em `scratch_<user>` a partir do Gold (ex.: sinistralidade por linha de negócio).

 **Checkpoint:** sua view consulta o Gold e reconcilia (2.801 Vida · 2.753 Previdência ativas).

## Bloco 3 09h50–10h45 Governança com Unity Catalog

O coração da self-service zone — **quem vê e constrói o quê**. Estrutura de catálogo/schema/grupos e **GRANTS; tags & Domain** + glossário/certificação; **lineage** automático; proteção de dados sensíveis de seguros com **row filters** e **column masking**; e fechamento com **audit** (system tables) e **custo** — a trilha de governança que sustenta todo o diagrama.

#### LAB · GOVERNANÇA (SANDBOX/SQL/20\_UC\_GOVERNANCE.SQL)

- GRANT SELECT no Gold a um **grupo** de participantes.
- Aplicar uma **tag de Domain** a um schema/tabela.
- **Column mask** em documento do cliente + valores (prêmio/sinistro).
- **Row filter** por região.
- Visualizar o **lineage** no Catalog Explorer.

✓ **Checkpoint:** coluna sensível mascarada para quem não é privilegiado; lineage bronze→gold→consumo visível.

**Bloco 4** 11h00–11h55

## CI/CD com Azure DevOps + Databricks Asset Bundles

Levar o self-service à produção com disciplina de engenharia: **Repos + GitFlow, Databricks Asset Bundles** (`databricks.yml`) empacotando jobs/notebooks, e um **pipeline Azure DevOps** (`azure-pipelines.yml`) que **valida** e faz **deploy** no sandbox via **service principal** (OAuth M2M).

### ✓ LAB · BUNDLE + PIPELINE

- `databricks bundle validate` no seu bundle (`sandbox/bundle/`).
- **Commit** numa branch → o pipeline Azure DevOps roda `validate + deploy -t dev` no sandbox.

✓ **Checkpoint:** o job do bundle aparece no sandbox, publicado pelo pipeline.

**Bloco 5** 11h55–12h30 **Delta Sharing — Open Sharing**

Como a self-service zone **recebe** o Gold do hub central / da Argentina: **Delta Sharing** (protocolo aberto), sem copiar dado. O lado **provider** cria um SHARE do Gold + um RECIPIENT; o lado **recipient** consome. Modela o fluxo **AR → BR**.

### ✓ LAB · OPEN SHARING (SANDBOX/SQL/30\_DELTA\_SHARING.SQL)

- **Provider:** CREATE SHARE do Gold + ADD TABLE + CREATE RECIPIENT.

- **Recipient:** consumir via `CREATE CATALOG ... USING SHARE` (ou cliente delta-sharing).

✓ **Checkpoint:** o recipient consulta o Gold via share, sem cópia dos dados.

## Bloco 6 12h30–13h05 Preparação de dados & Machine Learning

Sobre o Gold, preparamos *features* e treinamos um modelo de **propensão a fraude em sinistros** — classificação que gera um **score de risco** para priorizar investigação (rótulo `suspeita_fraude` no Gold).

### LAB · ML

- **Modelo:** GBT (Spark MLlib); baseline Regressão Logística; **AutoML** como acelerador.
- **MLOps:** MLflow + **Unity Catalog Model Registry** (no seu schema).

✓ **Checkpoint:** modelo registrado e versionado no UC, pronto para servir sob AI Gateway.

## Bloco 7 13h05–13h35 Databricks Apps & AI Gateway

**Databricks Apps** publica aplicações web (FastAPI/Streamlit) **dentro do Databricks**, com identidade e governança do Unity Catalog. Um app de **triagem de sinistros** lê o Gold e ranqueia os casos de maior risco; o **AI Gateway** governa o consumo de IA (rate limits, usage tracking, inference tables, guardrails).



App OmniPulse AI (referência)



Endpoint + AI Gateway

## Bloco 8 13h35–13h50 Orquestração & handoff

Um único **Lakeflow Job** encadeia o ciclo governado: (Gold pronto) → **treino** do modelo → **refresh** do dashboard AI/BI — dados, modelo e painel sempre **sincronizados**, com **lineage**, **tags de Domain** e o **share** no fluxo. É a self-service zone rodando de ponta a ponta, sob governança.

## Ambiente & pré-requisitos do sandbox

O cliente habilita um **workspace sandbox compartilhado**. Para os labs rodarem, confirme os itens abaixo antes do evento.



### UC + warehouse

Catálogo/schema do workshop no Unity  
Catalog + SQL warehouse serverless  
ligado.



### Grupo de participantes

Grants: USE + SELECT no Gold e  
CREATE SCHEMA para os  
scratch\_<user>.



### Delta Sharing

Habilitado no metastore (lab de Open  
Sharing, lado provider).



### Repos + Azure DevOps

Git integration + projeto Azure DevOps  
para o lab de CI/CD (service principal).



### Model Serving & Apps

Habilitados para os blocos de ML e  
Apps.



### Seed do Gold

Acesso prévio para popular o Gold +  
Genie + dashboard (scripts em  
sandbox/).



Repositório do workshop



Setup do sandbox ( [sandbox/](#) )

## Números de bolso (gabarito)

Valores aproximados da base sintética no Gold — para conferir os resultados dos labs.

**2.801**

apólices de Vida  
ativas

**2.753**

apólices de  
Previdência ativas

**~5,1%**

taxa de  
inadimplência

**~95%**

persistência  
(arrecadação)

261

sinistros suspeitos  
(10,4%)

196

sinistros de alto  
risco

~67

dias de liquidação  
média

177 mil

pagamentos de  
prêmio



×



Material de capacitação preparado pela Databricks. Utiliza uma base **sintética** no formato MetLife (seguros de vida, previdência, sinistros e distribuição), criada exclusivamente para fins de treinamento — não contém dados reais nem PII. Logo MetLife usado apenas para identidade visual do workshop.